




基于社交网络的金融产品 扩散方式研究

bb 巴适队

2025 年 11 月 2 日



摘要

数字金融的普及与社交生态的深度渗透，使得当下金融产品扩散模式由传统”渠道驱动”模式转向新型“社交渗透”模式。本研究基于 SNAP 中的 ego-Facebook 数据集和 Kaggle 中的选举债券数据集，以量化社交影响力对金融产品传播的影响，发掘潜在用户与意见领袖为目标，创造性提出潜在空间模型，通过模拟社交网络与金融网络，构建了一个基于社交网络与用户特征的金融产品传播分析框架。在该框架下，通过给定客户初始数据与社交关系网，模型能够自动识别出潜在用户、投资的期望和意见领袖及其影响力大小，企业可以据此给不同的用户定制不同的营销策略，增强企业的个性化推荐能力与用户粘度。最终在数据集上共找出 5 名意见领袖，以节点 2630 为例，其分别对三个项目产生了 -1395580、7284147、762127 的平均因果效应，P 值分别为 0.348、0.225、0.005，企业可根据该数据指导市场，模型具有实用价值与应用意义。

1 背景介绍与研究问题

数字金融的普及与社交生态的深度渗透正重塑金融产品的扩散逻辑，社交平台已成为金融信息传播的核心载体：以 W 银行为例，其依托 T 社交媒体的社交生态，累计服务近 4 亿个人客户与超 500 万中小微企业。社交与金融的深度融合，使得传统”渠道驱动”的产品扩散模式逐渐向”社交渗透”模式转型，社交影响力已成为决定金融产品市场渗透率的关键变量。

尽管如此，社交影响力驱动金融产品扩散的内在机制仍存在缺口。由于金融产品的信用属性与互联网中的信息不对称特性，社交网络的浅层分析无法很好地解释用户投资行为转化链路，且现有做法缺乏针对性，尚未构建完整的分析框架，难以指导实践中差异化社交运营策略的制定。

本报告聚焦于研究社交影响力对金融产品的扩散的影响，帮助企业发掘潜在用户。致力于填补金融产品特性-社交传播模式-用户采纳行为的研究空白，为金融机构制定精准社交营销策略、提升普惠金融覆盖效率提供可复制的实践范式，具有重要的理论价值与应用意义。

2 数据说明与描述

2.1 数据预处理说明

2.1.1 社交网络数据

本研究中社交网络数据来源于<https://snap.stanford.edu/data/>的 ego-Facebook 数据集，包含 4039 个节点，88234 条边，平均聚类系数 0.6055，是一个短路径、高聚类的社交网络数据。数据以 10 个中心（ego）节点与圈子（circle）的形式给出，从这些节点出发可遍历该网络中所有节点及其特征 [1]。




图 1: 0 号中心节点所连接的好友及朋友圈

2.1.2 金融产品数据

本研究中金融产品数据来源于<https://www.kaggle.com/showwatyougot/datasets>的选举债券数据集，分别从 23 个发行方和 1297 个购买方的角度记录了 2019.4 至 2024.1 共 26 轮的债券购买情况，分别包含 18871 和 20421 条投资记录，总金额达 1215 亿卢比。虽然选举债券的核心目的与运行模式与一般金融产品不同，但是其包含了投资者编号、投资金额以及投资时间等关键信息，这是个人隐私法规保护下互联网所公开的一般金融产品数据集所不能提供的。而在实际情况中，这些信息银行等金融机构能够内部掌握，因此依然可以使用本研究所提出的方法对一般的金融产品数据进行分析。

2.1.3 基于 K-means 聚类的节点-金融产品数据对齐

将选举债券数据集中的发行方数据与购买方数据通过 Bond Number 和 Prefix 字段合并，剔除不匹配的 130 条异常记录，可视化分析如下图。可以看出 BHARATIYA JANATA PARTY 拥有最多的投资者，同时获得了最多的投资，投资总人数和投资总额均呈现“一超多强”的特点。




图 2: 不同政党支持人数比例




图 3: 不同政党收到债券总量

Facebook 社交网络数据源与选举债券数据源没有直接关联，因此需要将社交网络中的节点与债券购买记录中的购买方相匹配。一方面，由于投资行为存在群体性且社交网络数据本身就是良聚类的，以此作为先验信息，对两个数据分别聚类，再将簇与簇、聚类中心与聚类中心一一对应；另一方面，由于数据源不相关，我们在类内的匹配过程中保持随机性。数据对齐的具体步骤如下：

Step1 首先 Facebook 数据中由 ego 节点组织而成的节点已形成 10 个自然簇 $E_1, E_2, \dots, E_{10}$, 然后对选举债券数据中的投资人取 $k = 10$ 进行 K-means 聚类, 得到簇 $B_1, B_2, \dots, B_{10}$.

Step2 其次分别将两组数据的 10 个簇按节点数量排序, 得到 $E_{(1)}, E_{(2)}, \dots, E_{(10)}$ 与 $B_{(1)}, B_{(2)}, \dots, B_{(10)}$, 并将两组数据的簇及其聚类中心按编号一一对应。

Step3 接下来在每一个 $\{E_{(j)}\}$ 中再进行 K-means 聚类, 其中参数 $k = k_j$ 基于轮廓系数确定, 得到子簇 $\{E_{(j)k_j}\}$, 然后对 $B_{(j)}$ 取 $k = k_j$ 进行 K-means 聚类, 得到子簇 $\{B_{(j)k_j}\}$.

Step4 最后将所有 $\{E_{(j)k_j}\}$ 和 $\{B_{(j)k_j}\}$ 的聚类中心一一对应，其余节点随机匹配，得到 Facebook 网络节点的投资历史数据。

2.2 模型的基本假设

- 假设 1: 社交网络数据中节点及其社交关系在短期内维持稳定, 信息交互即时、有效且准确。
- 假设 2: 已经发生过的投资行为不会被撤销, 这与债券这一金融产品的特性相适配。
- 假设 3: 金融产品的种类和数量在短期内维持稳定, 且在社交网络中的扩散是单向的。

3 数据建模与解读

3.1 基于节点影响力的意见领袖识别

3.1.1 潜在空间模型的基本框架

社交网络又称在线社会网络, 可以视为一个包含 N 个节点即用户的有向网络。设节点索引为 $1 \leq i \leq N$ 。定义邻接矩阵 $A = (a_{i_1 i_2}) \in \mathbb{R}^{N \times N}$, 其中若节点 i_1 关注节点 i_2 或者受其影响, 则 $a_{i_1 i_2} = 1$, 否则 $a_{i_1 i_2} = 0$ 。此外, $\forall 1 \leq i \leq N: a_{ii} = 0$, 即节点无自环。

在社交网络中, 节点的**影响力**直接反映了其传播信息的能力 [2]。在许多现实场景中, 网络中节点的影响力与其自身属性密切相关 [3], 例如在所获取的 Facebook 社交网络基图数据中, 节点的影响力与其工作、所在地、语言等因素密切相关。因此, 我们首先构建影响力与节点特征之间的关系模型。

定义节点 i 的影响力为 $\gamma_i \in \mathbb{R}^+$ ($1 \leq i \leq N$)。用 p 维向量 $X_i = (X_{ij})^\top \in \mathbb{R}^p$ ($1 \leq j \leq p$) 表示节点 i 的协变量, 令协变量矩阵为 $\mathbb{X} = (X_1, \dots, X_N)^\top \in \mathbb{R}^{N \times p}$ 。此时我们假设:

$$\log \gamma_i = \alpha + X_i^\top \beta \quad (1)$$

其中 $\alpha \in \mathbb{R}$ 称为冗余参数, $\beta = (\beta_j)^\top \in \mathbb{R}^p$ 为与特征向量相关联的 p 维系数向量。

在有向图中, **边生成概率**指的是两个节点之间形成一条有向边的概率, 刻画了节点受另一个节点影响的可能性。为构建边生成概率模型, 假设每个节点 i 在 d 维欧氏空间中存在一个潜在位置 $Z_i \in \mathbb{R}^d$, 所有节点的潜在位置构成矩阵 $\mathbb{Z} = (Z_1, \dots, Z_N) \in \mathbb{R}^{d \times N}$ 。对于 $1 \leq i_1 \neq i_2 \leq N$, 边生成概率 [4] 满足:

$$P(a_{i_1 i_2} = 1 \mid \mathbb{Z}, \mathbb{X}) = P(a_{i_1 i_2} = 1 \mid Z_{i_1}, Z_{i_2}, X_{i_2}) = \exp \left(-\frac{\|Z_{i_1} - Z_{i_2}\|^2}{2\gamma_{i_2}^2} \right) \quad (2)$$

边生成概率公式 (2) 与影响力定义式 (1) 共同构成**潜在空间模型** (Latent Space Model, LSM)。从公式

(2) 中可以看出, $a_{i_1 i_2} = 1$ 即节点 i_1 与 i_2 间存在有向边或者说节点 i_1 关注 i_2 的概率依赖于节点 i_1 与 i_2 潜在位置的距离以及接收端节点 i_2 的影响力这两个关键因素。为保证模型可识别性, 假设潜在位置 Z_i 独立服从标准正态分布, 且在给定 $\mathbb{Z}$ 的条件下边变量 $a_{i_1 i_2}$ 相互独立, $1 \leq i_1 \neq i_2 \leq N$ 。

3.1.2 影响力有关参数的估计

首先引入网络结构的相关概念 [5]:

定义 3.1. 入度定义为节点接收的有向边总数, 即其他节点对该节点的关注次数。数学上表示为 $d_i^{in} = \sum_{i'=1, i' \neq i}^N a_{i' i}$

其中 $a_{i' i} = 1$ 表示节点 i' 关注节点 i , $a_{i' i} = 0$ 则相反。入度是网络的一阶结构。

定义 3.2. 互惠性作为二阶结构, 指两个节点间的双向有向边关系, 即节点间相互关注。数学上表示为: 在 $a_{i_1 i_2} = 1$ 的条件下, $a_{i_2 i_1} = 1$ 的概率显著高于无条件概率, 记为事件 $a_{i_1 i_2} a_{i_2 i_1} = 1$ 。

定义 3.3. 传递性作为三阶结构, 指三个不同节点间的链式有向边关系, 反映网络的聚类效应。数学上表示为在 $a_{i_1 i_2} = 1$ 且 $a_{i_2 i_3} = 1$ 的条件下, $a_{i_1 i_3} = 1$ 的概率显著高于无条件概率, 记为事件 $a_{i_1 i_2} a_{i_2 i_3} a_{i_1 i_3} = 1$ 。

入度、互惠性以及传递性从不同层次反映了社交网络的结构特征以及网络中某节点对其他节点的影响。事实上, 基于三者均可构建潜在空间模型, 此处我们基于传递性构造系数向量 β 的估计, 因为传递性作为三阶网络结构, 相比入度和互惠性能提供更丰富的统计信息, 且在估计效率与稳定性上具有显著优势。在节点 i_3 被节点 i_2 关注且 i_2 被 i_1 关注的条件下, 节点 i_1 关注节点 i_3 的概率近似为

$$\pi_{tr}^{i_1 i_2 i_3} = P(a_{i_1 i_3} = 1 \mid a_{i_1 i_2} a_{i_2 i_3} = 1, \mathbb{X}) = \frac{\gamma_{i_3}}{(\gamma_{i_2}^2 + 2\gamma_{i_3}^2)^{1/2}} = \frac{\exp(\Delta_{i_3 i_2}^\top \beta)}{\{2 \exp(2\Delta_{i_3 i_2}^\top \beta) + 1\}^{1/2}} \quad (3)$$

其中 γ_i 为节点 i 的影响力, $\Delta_{i_3 i_2} = X_{i_3} - X_{i_2}$ 表示节点 i_3 与 i_2 的特征差异向量。 $\pi_{tr}^{i_1 i_2 i_3}$ 不依赖于 X_{i_1} , 不受冗余参数 α 的影响, 且当 $N \rightarrow \infty$ 时 $\pi_{tr}^{i_1 i_2 i_3}$ 严格大于 0。

定义以下损失函数

$$\mathcal{L}_{tr}(\beta) = - \sum_{\substack{i_1 \neq i_3 \\ i_2 \neq i_1, i_3}} \sum a_{i_1 i_2} a_{i_2 i_3} \left\{ a_{i_1 i_3} \log \pi_{tr}^{i_2 i_3} + (1 - a_{i_1 i_3}) \log(1 - \pi_{tr}^{i_2 i_3}) \right\}. \quad (4)$$

从而 β 的估计定义为

$$\hat{\beta}_{tr} = \arg \min_{\beta} \mathcal{L}_{tr}(\beta) \quad (5)$$

可以证明, $\hat{\beta}_{tr}$ 是 β 的 $N^{(1+\delta)/2}$ 相合估计, 其中 δ 为网络密度水平, 且冗余参数 α 的估计为

$$\hat{\alpha}_{tr} = \log\left\{\sum_{i_1 \neq i_2} \sqrt{a_{i_1 i_2}}\right\} - \log\left\{\sum_{i=1}^N \exp(X_i^\top \hat{\beta}_{tr})\right\} - \log(N-1) \quad (6)$$

3.1.3 意见领袖用户的识别

得到估计量 $\hat{\beta}_{tr}$ 和 $\hat{\alpha}_{tr}$ 后, 可由公式 (1) 计算出各节点的影响力 $\hat{\gamma}_i$ 。

为了更精准地识别意见领袖, 此处引入**用户活跃度**作为刻画意见领袖程度的另一指标, 因为意见领袖不仅要有较强的信息传播能力, 还应积极参与投资活动, 这样才更可能把自己的投资选择传递给其他用户 [6]。对此, 我们基于对齐后的数据, 统计每个用户购买债券的频数 η_i 作为用户活跃度指标。

然后使用**组合赋权法**计算**意见领袖值** $s_i = \omega_{\hat{\gamma}} \hat{\gamma}_i + \omega_{\eta} \eta_i$, 其中 $\omega_{\hat{\gamma}}$ 和 ω_{η} 分别为 $\{\hat{\gamma}_i\}_{i=1}^N$ 与 $\{\eta_i\}_{i=1}^N$ 经变异系数法与主观赋权法共同确定的权重。最后选取意见领袖值前 0.1% 的节点作为意见领袖 [6]。

3.2 基于边生成概率的金融产品扩散模拟

3.2.1 边生成概率与节点受影响概率的估计

根据上一节所得的节点影响力估计 $\hat{\gamma}_i$, 对任意两个取自标准正态分布的潜在位置 Z_{i_1}, Z_{i_2} 基于公式 (2) 计算节点间的边生成概率估计量 $\widehat{P(a_{i_1 i_2} = 1 \mid Z_{i_1}, Z_{i_2}, X_{i_2})} = \exp\left(-\frac{\|Z_{i_1} - Z_{i_2}\|^2}{2\hat{\gamma}_{i_2}^2}\right)$, 最后将边生成概率对 Z_{i_1}, Z_{i_2} 求期望, 得到节点 i_2 关注其他节点的平均概率 $p_{i_2} = \mathbb{E}_{Z_{i_1}, Z_{i_2}}[\widehat{P(a_{i_1 i_2} = 1 \mid Z_{i_1}, Z_{i_2}, X_{i_2})}]$, 这是因为潜在位置具有随机性, 取期望后才可刻画节点 i_2 的投资选择受网络中其他节点影响的概率。

3.2.2 金融产品扩散模拟的具体过程

将对齐后的投资者-金融产品数据视为历史数据, 我们基于 $\{p_i\}_{i=1}^N$ 对未来投资轮次中用户的投资行为变化进行模拟。具体而言, 对于产品 $j, j = 1, 2, \dots, m$, 其扩散过程可模拟如下:

Step1 记历史数据中第 k 轮次投资产品 j 的用户所构成的集合为 $B_{jk} = b_{jk}^{(1)}, b_{jk}^{(2)}, \dots, b_{jk}^{(\# \{B_{jk}\})}$, $k = 0, 1, \dots, 25$,

同时对同一轮次中发生多次投资的用户, 记录其投资次数为 $n_{jk}^{(l)}$;

Step2 对每一与 $b_{jk}^{(l)}$ 相连的节点 i , 计算受影响而投资的概率 $p_{ijk}^{(l)} = n_{jk}^{(l)} \xi^{25-k} p_i$, $\xi \in (0, 1)$ 为衰减系数;

Step3 若 $p_{ijk}^{(l)} > 0.6$, 则节点 i 进行一次 Bernoulli 试验, 以概率 $p_{ijk}^{(l)}$ 投资产品 j , 视为产品发生扩散;

Step4 对此前所有轮次中投资产品 j 的节点, 执行步骤 1-3, 最终就得到了下一轮次的投资结果。

3.3 基于因果推断的微观行为决策

本节聚焦微观结构，基于潜在结果框架 [7] 探究意见领袖的投资选择对周围节点投资行为的影响。

从历史数据中提取意见领袖 i 及其与之相连节点的投资记录，定义处理变量 $T_{i,j} \in \{0,1\}$ ， $T_{i,j} = 1$ 表示其投资了产品 j ，否则表示没有投资；响应变量 $Y_{i,j}(1)$ 表示意见领袖 i 投资的条件下与之相连节点的投资金额， $Y_{i,j}(0)$ 则表示意见领袖 i 未投资的条件下与之相连节点的投资金额。Neyman 提出的平均因果效应估计量 [8] 定义为 $\hat{\tau}_{i,j} = \hat{\bar{Y}}_{i,j}(1) - \hat{\bar{Y}}_{i,j}(0)$ ，其中 $\bar{Y}_{i,j}(1)$ 和 $\bar{Y}_{i,j}(0)$ 分别为所有投资记录中 $Y_{i,j}(1)$ 和 $Y_{i,j}(0)$ 的样本均值。 $\hat{\tau}_{i,j}$ 是真实因果效应 $\tau_{i,j}$ 的无偏估计，反映意见领袖 i 的投资选择对与之相连节点在第 j 个产品的投资行为的因果作用，从而定量刻画金融产品的微观扩散机制。

3.4 模型结果分析

3.4.1 意见领袖及其对用户投资行为的微观影响

根据 3.1 节中的方法从 4039 个节点中识别出表 1 所示的 5 名意见领袖及其相关属性。

表 1: 意见领袖及其相关属性

节点 id	活跃度	影响力	意见领袖值	投资总额（亿）	投资次数	投资产品数
2630	16	0.0085	0.8255	37.70	395	3
786	14	0.0088	0.7758	120.50	1205	7
734	13	0.0085	0.7267	82.10	821	8
1930	10	0.0090	0.6481	1.02	70	4
3987	10	0.0089	0.6438	9.23	95	5

根据 3.3 节中的方法，得到 2630 号节点的投资选择对周围节点投资行为的因果作用如表 2。

表 2: 2630 号节点的投资选择对周围节点投资行为的因果作用

产品名称	处理组记录数	控制组记录数	平均因果效应	p 值
ALL INDIA TRINAMOL CONGRESS	871	134	-1395580	0.348
BHARATIYA JANATA PARTY	335	737	7284147	0.225
PRESIDENT, ALL INDIA CONGRESS COMMITTEE	67	804	762127	0.005

可见，意见领袖在对周围节点在一些产品的投资上发挥较大的影响，能够显著影响金融产品的销售。

3.4.2 金融产品的宏观扩散效果

根据 3.2 节中的方法，对用户未来的投资行为进行模拟，标红的是新投资的节点，颜色深浅表示投资金额。




图 4: 金融产品的宏观扩散模拟

4 商业化应用与总结

基于上述模型、用户数据和项目数据，我们构建出一个集成式管理后台，分为用户数据、项目数据、平台维护三个大类，用户个人数据，社交关系网，用户投资数据等多个小类。内置搜索框架可以查看各个用户的意见领袖值和对于某个项目的平均因果效应。对于客户，我们还搭建了智能投顾智能体，辅助用户投资决策。



图 5: 后台页面与智能体示例

本研究使用潜在空间模型，以量化社交影响力对金融产品传播为目标，模拟社交网络中的传递效应，最终在数据集上找出 5 名意见领袖，且以节点 2630 为例，其分别对三个项目产生了 -1395580、7284147、762127 的平均因果效应，p 值分别为 0.348、0.225、0.005，这些指标对于指导金融产品的传播与促销方案的选择有关键性作用，企业可以据此给不同的用户指定不同的营销策略，增强企业的个性化推荐能力与用户粘度，具有实现价值与现实价值。

参考文献

- [1] Julian McAuley and Jure Leskovec. Learning to discover social circles in ego networks. In *Proceedings of the 26th International Conference on Neural Information Processing Systems - Volume 1*, NIPS'12, page 539–547, Red Hook, NY, USA, 2012. Curran Associates Inc.
- [2] 高帅. 在线社会网络中影响力度量和流行度预测问题研究. 博士论文, 山东大学, 2015.
- [3] Daniel K. Sewell and Yuguo Chen. Latent space models for dynamic networks with weighted edges. *Social Networks*, 44:105–116, 2016.
- [4] Peter D Hoff, Adrian E Raftery, and Mark S Handcock. Latent space approaches to social network analysis. *Journal of the American Statistical Association*, 97(460):1090–1098, 2002.
- [5] Xiangyu Chang, Danyang Huang, and Hansheng Wang. A popularity scaled latent space model for large-scale directed social network. *Statistica Sinica*, 2019.
- [6] 刘志明 and 刘鲁. 微博网络舆情中的意见领袖识别及分析. *系统工程*, 29(6):8–16, 1 2011.
- [7] Donald B. Rubin. Estimating causal effects of treatments in randomized and nonrandomized studies. *Journal of Educational Psychology*, 66:688–701, 1974.
- [8] Jerzy Splawa-Neyman, D. M. Dabrowska, and T. P. Speed. On the Application of Probability Theory to Agricultural Experiments. Essay on Principles. Section 9. *Statistical Science*, 5(4):465 – 472, 1990.

A 附录

A.1 符号说明

符号说明	
符号	含义
$\{E_i\}, i = 1, 2, \dots, 10$	节点按照与之相关的 ego 节点分类
$\{B_i\}, i = 1, 2, \dots, 10$	Merge 中投资人分类
N	节点数量
A	邻接矩阵
γ	影响力
p	特征维度，这里为 21 维
$X_{ij}, j = 1, 2, \dots, p$	第 i 个节点的第 j 个特征
α	冗余参数
β	与特征向量相关联的 p 维系数向量
Z_i	潜在位置

A.2 数据说明

Merge 文件有效数据说明：

表 1 运单画像

标签	变量含义	变量类型	取值
Name of the Political Party	正当名称（这里视为金融产品）	分类变量	
Prefix	债券前缀	分类变量	
Name of the Purchaser	购买者	分类变量	
Denominations	购买量（投资量）	连续变量	$\mathbb{Q}^+$
Date of Purchase	购买日期	连续变量	
local_node_id	购买者对应节点	分类变量	




图 7: ego_0 节点的社交网络

A.3 分析过程中产生的中间图




图 6: ego_0 节点的特征空间




图 9: ego_107 节点的社交网络




图 8: ego_107 节点的特征空间




图 11: ego_1684 节点的社交网络




图 10: ego_1684 节点的特征空间